Defiende el servidor · Informe

MLOps · Visualización 2 · 2026-II · **Grupo A** · Jorge Horacio Rojas Criollo y Maria Jimena Castaño Albarracin · 30 de octubre de 2026

Código: github.com/mjcastano29-tech/defiende-el-servidor (tags v1, v2) · Modelos: huggingface.co/Marimar2006/defiende-el-servidor · DVC: huggingface.co/datasets/Marimar2006/defiende-el-servidor-dvc · Índice de evidencias: entrega.md

Trabajo conjunto, desarrollado en clase desde el equipo de Maria Jimena: por eso los commits y los repositorios de Hugging Face aparecen en sus cuentas (mjcastano29-tech, Marimar2006).

Objetivo. Clasificar conexiones de UNSW-NB15 como normal (0) o ataque (1, clase positiva) y, sobre todo, versionar código, datos, experimentos y modelos de forma que otra persona pueda recuperar una versión concreta, saber de qué datos y experimento viene y usarla para predecir. Cadena de trazabilidad: **commit Git → referencia DVC → run de MLflow → revisión de Hugging Face**, enlazada por hashes.

1. Datos, auditoría y limpieza

Se usaron las particiones publicadas, descargadas el 2026-10-02 del SharePoint oficial de UNSW y del mirror indicado por el docente; ambas copias son idénticas byte a byte y su SHA-256 coincide con el anexo del taller. Los CSV traen BOM (se leen con utf-8-sig).

Archivo	Filas × col.	Ataque	Duplicados por entradas	Grupos contradictorios	NaN / '-' en service	SHA-256 (inicio)
UNSW_NB15_training-set.csv	175.341×45	68,1 %	74.301 (42,38 %)	229 (940 filas)	0 / 94.168	bec7dd5ec88dc2a0…
UNSW_NB15_testing-set.csv	82.332×45	55,1 %	28.386 (34,48 %)	6 (14 filas)	0 / 47.153	734fe6642edf758f…

Variables. 42 predictoras (39 numéricas y proto, service, state). Se excluyen label (respuesta), attack_cat (Normal ⇔ label 0: revela la respuesta) e id: es el número de fila 1…n de un archivo ordenado por clase, sin significado para el problema; solo se conserva para auditoría y para el row_id de las predicciones.

Política de limpieza. No se elimina ninguna fila, para no cambiar la población estudiada. Los duplicados (42 % del entrenamiento, 98 % de la familia Generic) y los grupos de entradas idénticas con etiqueta contradictoria se conservan; su riesgo es la fuga entre particiones, que se impide agrupando. service='-' (servicio no identificado) es una categoría propia. Categorías raras (<0,1 %) o no vistas (state ACC/CLO solo aparecen en test) van a una columna «infrecuente». El efecto de deduplicar se midió como experimento (E5).

Particiones. Entrenamiento y validación salen solo del archivo de entrenamiento con StratifiedGroupKFold (5 pliegues, semilla 42, primer pliegue = validación), usando como grupo el hash de las 42 variables: 140.779 filas de entrenamiento y 34.562 de validación, con 0 grupos compartidos. El test (82.332 filas) no se toca: 10,37 % de sus filas tiene entradas idénticas a filas de entrenamiento/validación; se reporta y se mide su efecto. Codificadores y escalado se ajustan solo con entrenamiento, dentro de un Pipeline de scikit-learn (log1p + StandardScaler en numéricas, OneHotEncoder en categóricas) que se guarda junto al estimador. DVC conserva dos versiones de datos: originales (data/raw, md5 ec34e6c9…) y preparados con sus particiones (data/processed, md5 f6c1bfa0…); la asignación por fila está en asignacion_splits.csv.

2. Experimentos (validación)

Siete configuraciones de dos familias (lineal y árboles) más una referencia, con las mismas particiones y cambiando una decisión a la vez. Las hipótesis se escribieron en params.yaml antes de entrenar (commit 86d0212). Cada run registra en MLflow hipótesis, parámetros, semilla, commit, datasets de entrada, métricas y el modelo completo. Política común de umbral: **máximo recall con FPR ≤ 5 % en validación**. Métricas con la clase ataque como positiva; si un denominador es 0, la métrica se reporta como 0.

ID	Familia · cambio	Hipótesis (resumen)	Umbral	Recall	Precisión	FPR	Macro-F1	Run ID
E0	Dummy (prior)	Piso: no distingue clases	1,000	0,0000	0,0000	0,0000	0,2429	a4bddefa…
E1 (v1)	Regresión logística	Lineal basta parcialmente (AUC>0,95)	0,789	0,9049	0,9746	0,0500	0,9108	ad45444b…
E2	E1 + class_weight balanced	Balancear solo mueve el umbral	0,635	0,9041	0,9746	0,0500	0,9102	67b93b03…
E3	HistGradientBoosting	Árboles mejoran recall	0,658	0,9468	0,9757	0,0500	0,9411	061b382f…
E4	E3 sin sttl/dttl/ct_state_ttl	Sin TTL baja poco	0,667	0,9424	0,9756	0,0500	0,9379	12d14b5e…
E5	E3 sin filas repetidas	Duplicados aportan poco	0,663	0,9433	0,9756	0,0500	0,9385	9c7b4d7e…
E6 (v2)	E3 con 500 it., 63 hojas, lr 0,05	Más capacidad: mejora <1 punto	0,667	0,9522	0,9759	0,0499	0,9452	b1caa191…

Lectura. Todas las hipótesis se confirmaron. E2 cambió nuestra opinión: balancear clases parecía necesario por la prevalencia invertida, pero con el umbral elegido explícitamente no aporta (con umbral 0,5 sí baja la FPR de 13,4 % a 8,1 %, solo porque desplaza el corte). El cambio de familia (E3) es lo que más aporta: +4,2 puntos de recall con la misma FPR y menor tiempo de entrenamiento. Quitar el TTL (E4), un artefacto del laboratorio, cuesta solo 0,4 puntos, y deduplicar (E5) cuesta 0,4 con 42 % menos filas. La comparación es justa porque comparte particiones, preprocesamiento, semilla y regla de umbral, y ningún grupo de entradas idénticas cruza entrenamiento y validación.

3. Versiones v1 y v2

	v1	v2
Modelo	E1 · regresión logística	E6 · HistGradientBoosting
Umbral	0,788667	0,667379
Recall val.	0,9049	0,9522
Precisión val.	0,9746	0,9759
FPR val.	0,0500	0,0499
Macro-F1 val.	0,9108	0,9452
Ataques no detectados / falsas alarmas (val.)	2.232 / 554	1.121 / 553
Git (tag → commit)	v1 → 57c2c870…	v2 → ea3a50fd…
MLflow run	ad45444b57f342e7b7df102aa9898abc	b1caa19139d54c2ea08d8984bcbb0399
Hugging Face (SHA)	18ca32ce72d39f02782a38d745185500aa5625cb	cab4044d0e3ae66a06ed1227bd4f5384e7808271
SHA-256 model.skops	7cdc9965a67ccd0342e8b54ebddaf6b84121e3498ddea9dbde27a859f0e221bc	24b3db2a677a40333f04ae24a3368dabea72ed7f963954301f1c749f42132673

v1 es la primera solución funcional: preprocesamiento, regresión logística y umbral elegidos e identificados. **v2** es la revisión basada en los experimentos: cambia la familia de modelo y sus hiperparámetros, con los mismos datos, particiones y política de umbral. **Mejora** el recall en 4,7 puntos (de 2.232 a 1.121 ataques no detectados en validación) y el macro-F1 de 0,911 a 0,945. **Empeora** la interpretabilidad (sin coeficientes directos) y el tamaño del artefacto (0,3 MB → 5,8 MB); la FPR no cambia porque ambos umbrales se fijan con la misma regla. **Errores aceptados**: ~5 % de conexiones normales alarmadas y ~4,8 % de ataques no detectados en validación. Cada versión se publicó en Hugging Face con el artefacto exacto del run de MLflow (mismo SHA-256), su config.json (umbral, regla, variables, métricas y linaje), dependencias y model card.

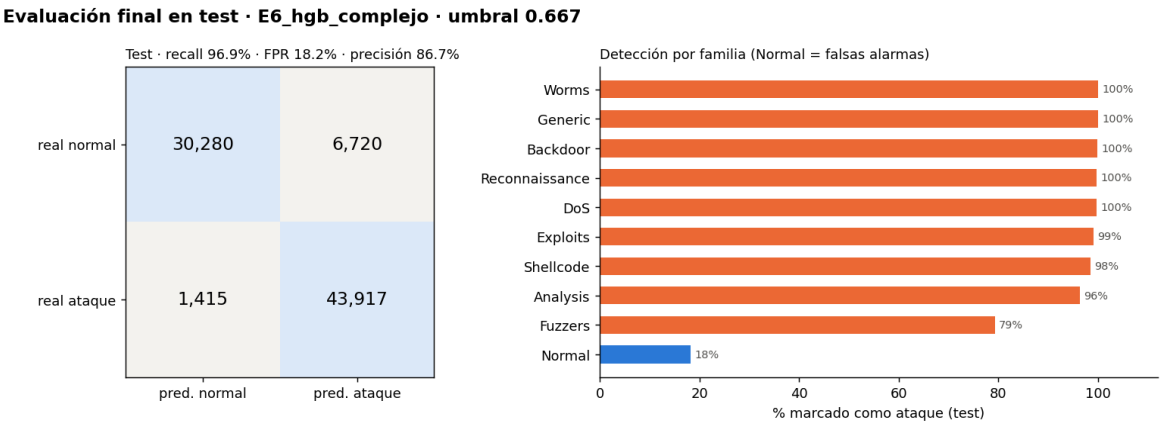
4. Elección del umbral

Un ataque ignorado cuesta más que una falsa alarma, pero un equipo de seguridad no puede revisar una avalancha de alertas falsas. Por eso fijamos un presupuesto de falsas alarmas (5 % del tráfico normal) y, dentro de él, maximizamos los ataques detectados; el desempate es macro-F1. El umbral se calcula sobre la curva ROC de validación (mayor TPR con FPR ≤ 0,05). Con 0,5 la v2 detectaría 97,6 % de los ataques pero alarmaría 8,3 % del tráfico normal. La selección se congeló antes del test: en el flujo de Prefect, la tarea comparar-y-congelar terminó a las 22:58:31.803 UTC y evaluar-test empezó a las 22:58:31.808 UTC (2026-10-14), y el criterio estaba en Git desde el commit 86d0212.

5. Evaluación final en test (solo v2, una vez)

	Recall	Precisión	FPR	Macro-F1	ROC-AUC	Matriz [[TN, FP], [FN, TP]]
Validación (v2)	0,9522	0,9759	0,0499	0,9452	0,9932	[[10.538, 553], [1.121, 22.350]]
Test completo (82.332 filas)	0,9688	0,8673	0,1816	0,8984	0,9845	[[30.280, 6.720], [1.415, 43.917]]
Test sin entradas vistas (73.791)	0,9634	0,8540	0,1773	0,8945	—	—

El resultado **empeoró y se conserva**: el recall se mantiene (96,9 %), pero la tasa de falsas alarmas sube de 5 % a 18,2 %. El solapamiento con entrenamiento no lo explica (sin esas filas, FPR 17,7 %). La causa es un cambio en el tráfico normal entre archivos: en test, 41 % de las conexiones normales tiene sttl=254 (20 % en entrenamiento) y son las que el modelo confunde. Reponderar la validación con esa mezcla ya duplica la FPR esperada (≈10,6 %). Un diagnóstico posterior, declarado y sin efecto en la selección, muestra que ningún modelo se habría salvado (FPR en test entre 13,8 % y 18,2 %, también sin TTL). La capacidad de ordenar se conserva (ROC-AUC 0,9845); lo que no se traslada es el umbral. Los ataques no detectados se concentran en Fuzzers (21 % sin alerta; 1.257 de 1.415). Las predicciones por fila (row_id, y_true, score_attack, y_pred) y las métricas se recalculan desde predicciones-test.csv y coinciden con la evaluación original.



Integridad del test

El test se evaluó una sola vez, el 14 de octubre, cuando regía la primera guía; la guía actualizada (16 de octubre) no cambió la decisión: v2 es exactamente la elección congelada entonces. La secuencia está respaldada por registros fechados exportados en evidencias/congelacion/ y verificables en Git y en la base de MLflow recuperable con DVC:

Hora UTC (2026-10-14)	Fuente	Evento
22:52:53.000	git	criterio de selección e hipótesis en params.yaml (antes de entrenar)
22:55:43.000	git	código con el que se ejecutó el pipeline (runs canónicos)
22:56:00.520	prefect	inicio del flujo (entrenamiento de E0–E6)
22:58:26.324	mlflow	última métrica de validación del run elegido
22:58:31.803	prefect	fin de comparar-y-congelar (elección escrita en seleccion.json)
22:58:31.808	prefect	inicio de evaluar-test
22:58:34.773	mlflow	primera métrica de test del run elegido
23:01:45.000	git	commit de resultados: seleccion.json y test_metrics.json

No existe un commit de seleccion.json anterior al test, porque elección y evaluación ocurrieron en la misma ejecución del pipeline; no se reconstruyó ni se fechó a posteriori ningún commit. La re-ejecución del 16 de octubre y el recálculo de las evidencias usan el mismo modelo congelado y dan cifras idénticas; el diagnóstico de otros modelos en test es posterior, está declarado y no modificó la selección.

6. Recuperación de versiones

En una carpeta y un entorno virtual nuevos, sin cachés de pip, DVC ni Hugging Face (scripts/recuperacion.sh): se clonó el código, se instalaron las dependencias fijadas, se recuperaron con dvc pull los datos originales y preparados desde el remoto público (huellas verificadas), se descargaron v1 y v2 por su SHA completo, se cargaron preprocesamiento, modelo y umbral, y se predijo sobre 20 filas fijas de validación (10 normales y 10 ataques). Resultado: **OK**. v1: predicciones idénticas, máx. |Δscore| = 2e-16; v2: idénticas, máx. |Δscore| = 1e-16 (tolerancia 1e-09). El SHA-256 del modelo descargado coincide con el registrado en MLflow, DVC y la model card.

7. Limitaciones

UNSW-NB15 es tráfico sintético de laboratorio (2015): no demuestra eficacia en una red actual. La prevalencia de ataque (55–68 %) es irreal; con ataques raros la precisión caería mucho para la misma FPR. El TTL y las filas repetidas son huellas del laboratorio. El umbral depende del tráfico normal con el que se calibra y debe recalibrarse en la red de destino; el test muestra ese riesgo. El test se evaluó el 14 de octubre con la primera guía; la selección se hizo solo con validación y no se cambió con la guía actualizada. Las variables ct_* requieren estado de las 100 conexiones previas para usarse en línea.

Referencias

Moustafa, N. & Slay, J. (2015). UNSW-NB15: a comprehensive data set for network intrusion detection systems. MilCIS, IEEE. https://research.unsw.edu.au/projects/unsw-nb15-dataset

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825–2830.

Documentación de DVC (dvc.org/doc), MLflow Tracking (mlflow.org/docs), Hugging Face Hub (huggingface.co/docs/hub: descarga por revisión y model cards).

Uso de IA: Claude Code (Anthropic) como asistente de programación y redacción; ver entrega.md.